

熵及最大模型

熵的计算：

$$H(x) = - \sum_{x \in X} p(x) \log_2 p(x)$$

最大熵原理：

对一个随机事件的概率分布进行预测时，预测应当满足全部已知的约束，而对未知的情况不要做任何主观假设。

1. 满足已知信息（约束条件）
2. 不做任何未知假设（剩下的等概率）

此时概率分布最均匀，预测的风险最小，得到的概率分布的熵是**最大的**

最大熵原理的推导：

拉格朗日约束+求导

• Lagrange乘子法构造 $L(p, \lambda)$: $L(p, \lambda) = - \sum_{i=1}^n p_i \log p_i + \lambda (\sum_{i=1}^n p_i - 1)$


• 求解 $\text{Max } L(p, \lambda)$: 满足导数为0?

$$\frac{\partial L(p, \lambda)}{\partial p_i} = -\log p_i - 1 + \lambda = 0$$

$$p_i = e^{\lambda-1}, i = 1, 2, \dots, n$$

• 将其带入到约束条件中, $\sum_{i=1}^n p_i = ne^{\lambda-1} = 1$

• 因此, $e^{\lambda-1} = \frac{1}{n}$, $p_1 = p_2 = \dots = p_n = \frac{1}{n}$



约束条件：

$$P(A) + P(B) + P(C) + P(D) + P(E) = 1$$

$$P(A) + P(B) = 3/10$$

$$P(C) + P(D) + P(E) = 7/10$$

联合熵：

$$H(X, Y) = - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 p(x, y)$$

条件熵：

$$H(Y | X) = \sum_{x \in X} p(x) H(Y | X = x)$$

$$= - \sum_{x \in X} \sum_{y \in Y} p(x, y) \log_2 p(y | x)$$

Y \ X	1	2	3	4
1	1/8	1/16	1/32	1/32
2	1/16	1/8	1/32	1/32
3	1/16	1/16	1/16	1/16
4	1/4	0	0	0

$$\text{注意: } H(Y | X = x) = H\left(\frac{p(x, y)}{p(x)}\right)$$

连锁规则：

$$H(X, Y) = H(X) + H(Y | X)$$

$$H(X, Y) = H(Y) + H(X | Y)$$


互信息：Y 的值透露了多少关于 X 的信息

$I(X;Y)$ ：大于 0 关联度强；等于 0 关联度弱；小于 0 互补关系

$$I(X;Y) = H(X) - H(X|Y)$$

$$\begin{aligned} I(X;Y) &= H(X) - H(X|Y) \\ &= - \sum_{x \in X} p(x) \log_2 p(x) + \sum_{x \in X} \sum_{y \in Y} p(x,y) \log_2 p(x|y) \\ &= \sum_{x \in X} \sum_{y \in Y} p(x,y) (\log_2 p(x|y) - \log_2 p(x)) \\ &= \sum_{x \in X} \sum_{y \in Y} p(x,y) \left(\log_2 \frac{p(x|y)}{p(x)} \right) \\ I(X;Y) &= \sum_{x \in X} \sum_{y \in Y} p(x,y) \log_2 \frac{p(x,y)}{p(x)p(y)} \end{aligned}$$

关系图解：



双字耦合度：两字结合强度

$$Couple(\text{教, 务}) = \frac{N(\text{教务})}{N(\text{教务}) + N(\text{教 * 务})}$$

形式语言与自动机

形式语法的定义+四元组内容：

形式语法是一个 4 元组 $G = (N, \Sigma, P, S)$ ，其中 N 是非终结符的有限集合（有时也叫变量集或句法种类集）； Σ 是终结符的有限集合，且 $N \cap \Sigma = \emptyset$ ； $V = N \cup \Sigma$ 称为总词汇表； P 是一组重写规则的有限集合，即 $P = \{\alpha \rightarrow \beta\}$ ，其中， α, β 是 V 中元素构成的串，即 $\alpha, \beta \in V^*$ ，但 α 中至少应含有一个非终结符号； $S \in N$ ，称为句子符或初始符。

N：非终结符 Σ ：终结符 P：重写规则 S：开始（START/Sentence）

最左推导：

只改写最左边的非终结符

最右推导：

只改写最右边的非终结符

判别语法类型：0-3 型

3 型文法/正则文法： B 非终结 $+x$ 终结

$$A \rightarrow Bx, \text{ 或 } A \rightarrow x, \text{ 其中 } A, B \in N, x \in \Sigma$$

2 型文法/上下文无关文法： α 为字符串

$$A \rightarrow \alpha, \text{ 其中 } A \in N, \alpha \in (N \cup \Sigma)^*$$

1 型文法/上下文有关文法： α 字符串 $+A$ 非终结 $+\beta$ 字符串

$$\alpha A \beta \rightarrow \alpha \gamma \beta, \text{ 其中 } A \in N, \alpha, \beta, \gamma \in (N \cup \Sigma)^*$$

0 型文法/无约束文法： α, β 字符串

$$\alpha \rightarrow \beta, \text{ 其中 } \alpha, \beta \in (N \cup \Sigma)^*$$

每一个正则文法都是上下文无关文法，每一个上下文无关文法都是上下文有关文法，而每一个上下文有关文法都是 0 型文法，即：


$$L(G_0) \supseteq L(G_1) \supseteq L(G_2) \supseteq L(G_3)$$

上下文无关文法派生树：画派生树+反推规则

例如， $G = (\{S, A\}, \{a, b\}, P, S)$

P: $S \rightarrow bA$ $A \rightarrow bAA$ $A \rightarrow a$


G 所产生的句子 $bbaa$ 可以由下面的生树表示：



二义性：一个文法 G 不只有一颗派生树，那么这个文法就是二义性的

例： $G(E): E \rightarrow E + E \mid E * E \mid (E) \mid E - E \mid i$

对于句子 $i + i * i$ 有两棵对应的分析树。



有限自动机+五元组


确定的有限自动机 M 是一个五元组： $M = (\Sigma, Q, \delta, q_0, F)$

Σ 是输入符号的有穷集合（外部输入内容/输入带）
 Q 是状态的有限集合（机器内部状态/有限控制头）
 $q_0 \in Q$ 是初始状态； F 是终止状态集合，且 $F \subseteq Q$
 δ 是从 $Q \times \Sigma$ 到 Q 的映射，称为状态转移函数。


状态转换图+某个句子能否被接受：

状态变换图

映射 $\delta(q, a) = q'$ 可以由状态变换图描述。




为了明确起见，终止状态用双圈表示，起始状态用有“开始”标记的箭头表示。如：



◆DFA 定义的语言

链 $x = 110101$ 被 M 接受。
 $T(M) = \{\text{含偶数个0和偶数个1的链}\}$




正则文法、有限自动机：可以相互转换

定理 1: 若 $G = (V_N, V_T, P, S)$ 是一个正则文法，则存在一个有限自动机 $M = (\Sigma, Q, \delta, q_0, F)$ ，使得： $T(M) = L(G)$ 。

定理 2 若 $M = (\Sigma, Q, \delta, q_0, F)$ 是一有限自动机，则存在正则文法 $G = (V_N, V_T, P, S)$ ，使得： $L(G) = T(M)$ 。

解·根据右线性正规文法构造有限自动机的方法，构造 $M = (\{A, B, C, D, f\}, \{0, 1\}, \delta, \{A\}, \{f\})$ ，其中
 $\delta(A, 0) = f, \delta(A, 1) = B, \delta(B, 0) = D, \delta(B, 1) = C$
 $\delta(C, 0) = f, \delta(C, 1) = D, \delta(D, 0) = D, \delta(D, 1) = D$
 由本例中的右线性正规文法 G 构造的 M 对应的状态转换图如图 3-19 所示，图中 A 为 M 的初态结点， f 为 M 的终态结点。



图·3-19·例·3.17·对应的状态转换图

注意： $A \rightarrow aB$ 画为 $A \xrightarrow{a} B$ ；新加终结形态 f

自动机与文法对应：

有限自动机---3 型文法/正则文法
 下推自动机---2 型文法/上下文无关
 线性带限自动机---1 型文法/上下文有关
 图灵机---0 型文法/无约束文法

隐马尔可夫模型

马尔可夫假设：

假设 1：如果在特定情况下，系统在时间 t 的状态只与其在时间 $t-1$ 的状态相关，则该系统构成一个离散的一阶马尔可夫链：

$$p(q_t = S_j | q_{t-1} = S_i, q_{t-2} = S_k, \dots) = p(q_t = S_j | q_{t-1} = S_i)$$


假设 2：如果只考虑公式独立于时间的随机过程，即所谓的不动性假设，状态与时间无关，那么：

$$p(q_t = S_j | q_{t-1} = S_i) = a_{ij}, \quad 1 \leq i, j \leq N$$

马尔可夫状态图：

给定状态图计算状态序列概率

- 零概率的转移弧省略。
- 每个节点上所有发出弧的概率之和等于1。



状态序列 $S_1, \dots, S_T$ 的概率：

$$\begin{aligned} p(S_1, \dots, S_T) &= p(S_1) \times p(S_2 | S_1) \times p(S_3 | S_1, S_2) \times \dots \times p(S_T | S_1, \dots, S_{T-1}) \\ &= p(S_1) \times p(S_2 | S_1) \times p(S_3 | S_2) \times \dots \times p(S_T | S_{T-1}) \\ &= \pi_{S_1} \prod_{t=1}^{T-1} a_{S_t S_{t+1}} \quad \dots (6.5) \end{aligned}$$

其中， $\pi_i = p(q_1 = S_i)$ ，为初始状态的概率。

$$\begin{aligned} p(t, i, p) &= p(S_1 = t) \times p(S_2 = i | S_1 = t) \times p(S_3 = p | S_2 = i) \\ &= 1.0 \times 0.3 \times 0.6 \\ &= 0.18 \end{aligned}$$

隐马尔可夫模型： Q 、 V 、 A 、 B 、 π

Q 所有可能状态集合

V 所有可能观测集合

A 状态转移矩阵 a_{ij} 状态 i 到状态 j

B 观测概率矩阵 每一行为一种状态

π 初始状态概率向量

隐马尔可夫模型的三个问题：输入是什么？要解决的问题是什么？

O 为观测序列-（红，白，红）

问题	名称	描述	已知	求解
1	识别问题 (概率计算)	如何评估模型与观测序列之间的匹配程度	$\lambda = (A, B, \pi)$ $O = (o_1, o_2, \dots, o_T)$	$P(O \lambda)$
2	学习问题 (学习算法)	如何训练模型使其最好地描述观测数据	$O = (o_1, o_2, \dots, o_T)$	$\lambda = (A, B, \pi)$ 使得 $P(O \lambda)$ 最大
3	解码问题 (预测算法)	如何根据观测序列推断出隐藏的状态序列	$\lambda = (A, B, \pi)$ $O = (o_1, o_2, \dots, o_T)$	使 $P(O \lambda)$ 最大的状态序列 $I = (i_1, i_2, \dots, i_T)$

前向算法：只考虑相邻状态 $\alpha_{t+1}(j) = [\sum_{i=1}^N \alpha_t(i) a_{ij}] \times b_j(o_{t+1})$

$\alpha_t(i)$ 定义为时刻 t 部分观测序列为 $o_1, o_2, \dots, o_t$ 且状态为 q_i 的概率。

前向算法的步骤

(1) 初值计算： $t=1$ 的观测联合概率

$$\delta_1(i) = \pi_i b_i(o_1) \quad i = 1, 2, \dots, N$$

(2) 递推计算： $t=2, 3, \dots, T$ 的观测联合概率

$$\delta_t(i) = \left[\sum_{j=1}^N \delta_{t-1}(j) a_{ji} \right] b_i(o_t) \quad i = 1, 2, \dots, N$$

(3) 终止计算：累加 $t=1$ 到 T 的观测联合概率

$$P(O|\lambda) = \sum_{i=1}^N \delta_T(i)$$

为什么相加？
N个状态中，有1个观测到就行

(3) 终止计算

$$P(O|\lambda) = \sum_{i=1}^3 \delta_3(i) = 0.04187 + 0.035512 + 0.052836 = 0.130218$$

为什么相加？
3个盒子中，有1个取到红球就行

已知例1的 $\lambda = (A, B, \pi)$ ，设 $T=3$ ， $O = (\text{红}, \text{白}, \text{红})$ ，试用前向算法计算 $P(O|\lambda)$ 。

(1) 初值计算

$$\delta_1(1) = \pi_1 b_1(o_1) = 0.2 \times 0.5 = 0.10$$

时刻1从盒子1抽取出1个红球的概率

$$\delta_1(2) = \pi_2 b_2(o_1) = 0.4 \times 0.4 = 0.16$$

$$\delta_1(3) = \pi_3 b_3(o_1) = 0.4 \times 0.7 = 0.28$$

(2) 递推计算

$$\delta_2(1) = \left[\sum_{i=1}^3 \delta_1(i) a_{i1} \right] b_1(o_2) = 0.154 \times 0.5 = 0.077$$

$0.10 \times 0.5 + 0.16 \times 0.3 + 0.28 \times 0.2 = 0.154$

$$\delta_2(2) = \left[\sum_{i=1}^3 \delta_1(i) a_{i2} \right] b_2(o_2) = 0.184 \times 0.6 = 0.1104$$

$$\delta_2(3) = \left[\sum_{i=1}^3 \delta_1(i) a_{i3} \right] b_3(o_2) = 0.202 \times 0.3 = 0.0606$$

$$\delta_3(1) = \left[\sum_{i=1}^3 \delta_2(i) a_{i1} \right] b_1(o_3) = 0.08374 \times 0.5 = 0.04187$$

$0.077 \times 0.5 + 0.1104 \times 0.3 + 0.0606 \times 0.2 = 0.08374$

$$\delta_3(2) = \left[\sum_{i=1}^3 \delta_2(i) a_{i2} \right] b_2(o_3) = 0.08878 \times 0.4 = 0.035512$$

$$\delta_3(3) = \left[\sum_{i=1}^3 \delta_2(i) a_{i3} \right] b_3(o_3) = 0.07548 \times 0.7 = 0.052836$$

- 1) 计算从一轮盒子 1/2/3 开始的概率+抽出红
- 2) 一轮盒子 1/2/3 转到二轮盒子 1/2/3+抽出白

$\delta_2(1)$: 一轮盒子 123--->二轮盒子 1+白
 $\delta_2(2)$: 一轮盒子 123--->二轮盒子 2+白
 $\delta_2(3)$: 一轮盒子 123--->二轮盒子 3+白

- 3) 二轮盒子 1/2/3 转到三轮盒子 1/2/3+抽出红
- 4) Σ 最后所有的概率

后向算法： $\beta_t(i) = \sum_{j=1}^N a_{ij} b_j(o_{t+1}) \times \beta_{t+1}(j)$

$\beta_t(i)$ 定义为在时刻 t 状态为 q_i 的条件下，从 $t+1$ 到 T 的部分观测序列为 $o_{t+1}, o_{t+2}, \dots, o_T$ 的概率。

n-1 轮算 n 轮的抽取颜色

- 1) 三轮盒子 1/2/3 后面已无观测，初始化为 1
 $\beta_3(1) = 1, \beta_3(2) = 1, \beta_3(3) = 1$
- 2) 二轮盒子 1/2/3 转到三轮盒子 1/2/3 + 抽出红

转移+三轮选择盒 123+三轮抽取红

$\beta_2(1)$: 二轮盒子 1 ---> 三轮盒子 1/2/3 + 红
 $\beta_2(2)$: 二轮盒子 2 ---> 三轮盒子 1/2/3 + 红
 $\beta_2(3)$: 二轮盒子 3 ---> 三轮盒子 1/2/3 + 红

3) 一轮盒子 1/2/3 转到二轮盒子 1/2/3+三轮抽取白

$\beta_1(1)$: 一轮盒子 1 ---> 二轮盒子 1/2/3 + 白
 $\beta_1(2)$: 一轮盒子 2 ---> 二轮盒子 1/2/3 + 白
 $\beta_1(3)$: 一轮盒子 3 ---> 二轮盒子 1/2/3 + 白

4) Σ 抽盒子概率 - π_i * 抽取颜色概率 * 最后概率 - $\beta_1(n)$

$\gamma_t(i)$ 表示在时刻 t 处于状态 q_i 的概率;

$\xi_t(i, j)$ 表示在时刻 t 处于状态 q_i 且在时刻 $t + 1$ 处于状态 q_j 的联合概率。

学习算法：Baum Welch

原理是期望值最大化(EM)

$\alpha_t(i)$ 前向概率; $\beta_t(i)$ 后向概率

$$\gamma_t(i) = \frac{\alpha_t(i)\beta_t(i)}{P(O|\lambda)} = \frac{\alpha_t(i)\beta_t(i)}{\sum_{j=1}^N \alpha_t(j)\beta_t(j)}$$

$\gamma_t(i)$: 时刻 t 处于状态 q_i 的概率。

$$\xi_t(i, j) = \frac{\alpha_t(i)a_{ij}b_j(o_{t+1})\beta_{t+1}(j)}{\sum_{i=1}^N \sum_{j=1}^N \alpha_t(i)a_{ij}b_j(o_{t+1})\beta_{t+1}(j)}$$

$\xi_t(i, j)$: 时刻 t 处于状态 q_i , 并且时刻 $t + 1$ 处于状态 q_j 的联合概率。

预测算法：维特比算法（动态规划算法）

输入：模型 $\lambda = (A, B, \pi)$ 和观测 $O = (o_1, o_2, \dots, o_T)$;

$\delta_t(i)$ 计算最优概率：在时刻 t 状态为 i 的所有单个路径 $(i_1, i_2, \dots, i_t)$ 中概率最大值。

$\psi_t(i)$ 求解最优前驱

例题：

1) 计算一轮盒子 1/2/3 抽出红概率

2) 一轮盒子 1/2/3 ---> 二轮盒子 1/2/3+白 + 求出前驱（一轮盒子）

一轮盒子 1/2/3 ---> 二轮盒子 1 + 白
一轮盒子 1/2/3 ---> 二轮盒子 2 + 白
一轮盒子 1/2/3 ---> 二轮盒子 3 + 白

3) 二轮盒子 1/2/3 ---> 二轮盒子 1/2/3 + 红 + 求出前驱（二轮盒子）

二轮盒子 1/2/3 ---> 三轮盒子 1 + 红
二轮盒子 1/2/3 ---> 三轮盒子 1 + 红
二轮盒子 1/2/3 ---> 三轮盒子 1 + 红

4) 最后一轮找最大的盒子，内部找最大对应的前驱即可


过程 (红, 白, 红)

$$A = \begin{bmatrix} 0.5 & 0.2 & 0.3 \\ 0.3 & 0.5 & 0.2 \\ 0.2 & 0.3 & 0.5 \end{bmatrix}, B = \begin{bmatrix} 0.5 & 0.5 \\ 0.4 & 0.6 \\ 0.7 & 0.3 \end{bmatrix}, \pi = (0.2, 0.4, 0.4)^T$$

1) $P_{1(1)} = a_{12} \cdot a_{21} = 0.1$

$P_{1(2)} = 0.4 \cdot 0.4 = 0.16$

$P_{1(3)} = 0.4 \cdot 0.7 = 0.28$



2) $P_{2(1)} = \max\{a_{11} \cdot a_{11}, a_{16} \cdot a_{13}, a_{21} \cdot a_{21}\} \cdot a_{11}$

$= 0.28 \quad \psi_{2(1)} = 3$

$P_{2(2)} = \max\{a_{11} \cdot a_{12}, a_{16} \cdot a_{11}, a_{28} \cdot a_{13}\} \cdot a_{11}$

$= 0.16 \quad \psi_{2(2)} = 3$

$P_{2(3)} = \max\{a_{11} \cdot a_{13}, a_{16} \cdot a_{12}, a_{28} \cdot a_{11} \cdot a_{13}\}$

$= 0.04 \cdot 2 \quad \psi_{2(3)} = 3$ 3号前驱

3) $P_{3(1)} = \max\{a_{28} \cdot a_{11}, a_{16} \cdot a_{13}, a_{16} \cdot a_{12}\} \cdot a_{11}$

$= 0.076 \quad \psi_{3(1)} = 2$

$P_{3(2)} = \max\{a_{28} \cdot a_{12}, a_{16} \cdot a_{11}, a_{16} \cdot a_{13}\}$

$= 0.1 \cdot 0.048 \quad \psi_{3(2)} = 2$ 2号

$P_{3(3)} = \max\{a_{28} \cdot a_{13}, a_{16} \cdot a_{12}, a_{16} \cdot a_{11}\}$

$= 0.014 \quad \psi_{3(3)} = 3$ 3号前驱

3号节点

条件随机场

马尔可夫的性质：

成对的、局部的、全局的马尔可夫性 ---> 概率无向图模型

最大团分解：

若 C 是无向图 G 的一个团，并且不能再加进任何一个 C 外的结点使其成为一个更大的团，则称此 C 为最大团。

条件随机场：

特征函数：转移特征函数+特征状态函数

$$P(y | x) = \frac{1}{Z(x)} \exp \left(\sum_{i,k} \lambda_k t_k(y_{i-1}, y_i, x, i) + \sum_{i,l} u_l s_l(y_i, x, i) \right)$$

计算非规范化概率例：

例 11.1 设有一标注问题：输入观测序列为 $x = (x_1, x_2, x_3)$ ，输出标记序列为 $y = (y_1, y_2, y_3)$ ， y_1, y_2, y_3 取值于 $y = \{1, 2\}$ 。

假设特征 t_k, s_l 和对应的权值 λ_k, u_l 如下：

$$t_1 = t_1(y_{i-1}, y_i, y_i, x, i) = 1, y_i = 2, x_i = 2, i = 2, 3, \lambda_1 = 1$$

这里只注明特征取值为 1 的条件，取值为 0 的条件省略，即

$$t_1(y_{i-1}, y_i, x, i) = \begin{cases} 1, & y_{i-1} = 1, y_i = 2, x_i = 2, i = 2, 3 \\ 0, & \text{其他} \end{cases}$$

下同。

$$t_2 = t_2(y_{i-1}, y_i, y_i, x, i) = 1, y_i = 1, x_i = 2, \lambda_2 = 0.6$$

$$t_3 = t_3(y_{i-1}, y_i, y_i, x, i) = 2, y_i = 1, x_i = 3, \lambda_3 = 1$$

$$t_4 = t_4(y_{i-1}, y_i, y_i, x, i) = 2, y_i = 1, x_i = 2, \lambda_4 = 1$$

$$t_5 = t_5(y_{i-1}, y_i, y_i, x, i) = 2, y_i = 2, x_i = 3, \lambda_5 = 0.2$$

$$s_1 = s_1(y_i, x, i) = 1, x_i = 1, \mu_1 = 1$$

$$s_2 = s_2(y_i, x, i) = 2, x_i = 2, i = 1, 2, \mu_2 = 0.5$$

$$s_3 = s_3(y_i, x, i) = 1, x_i = 1, i = 2, 3, \mu_3 = 0.8$$

$$s_4 = s_4(y_i, x, i) = 2, x_i = 3, \mu_4 = 0.5$$

$y_1 \rightarrow y_2$

$$y_1=1, y_2=1, \lambda_1=0.6$$

$$y_1=1, y_2=2, \lambda_1=1$$

$$y_1=2, y_2=1, \lambda_1=1$$

$$y_1=2, y_2=2, \lambda_1=0.2$$

$y_2 \rightarrow y_3$

$$y_2=1, y_3=1, \lambda_2=0.6$$

$$y_2=1, y_3=2, \lambda_2=1$$

$$y_2=2, y_3=1, \lambda_2=1$$

$$y_2=2, y_3=2, \lambda_2=0.2$$

y_1

$$y_1=1, \mu_1=1$$

$$y_1=2, \mu_1=0.5$$

y_2

$$y_2=1, \mu_2=0.8$$

$$y_2=2, \mu_2=0.5$$

y_3

$$y_3=1, \mu_3=0.8$$

$$y_3=2, \mu_3=0.5$$

求 $(2, 1, 2)$ 非规范化概率

可以取到 t_k 或 s_l 的 $\Rightarrow t/s$ 取为 1

$$\begin{aligned} & 1 + 1 + 1 + 0.5 + 0.8 + 0.5 = 3.8 \quad \exp(3.8) \\ & 2 + 1 + 0.8 = 3.8 \end{aligned}$$

全局特征函数 f_k (了解)：

$$f_k(y_{i-1}, y_i, x, i) = \begin{cases} t_k(y_{i-1}, y_i, x, i), & k = 1, 2, \dots, K_1, \\ s_l(y_i, x, i), & k = K_1 + l; l = 1, 2, \dots, K_2. \end{cases}$$

条件随机场的矩阵形式：

$$M_i(x) = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$$

a_{ij} = 前一个标签 i 转移到当前标签 j 的概率 + 标签 j 的概率

归一化因子： $Z(x) = \prod_{i=1}^n M_i(x)$

前向/后向递推计算：

前向：

$$\alpha_i^T(x) = \alpha_{i-1}^T(x)M_i(x)$$

$$Z(x) = \alpha_i$$

后向：

$$\beta_i(x) = M_{i+1}(x)\beta_{i+1}(x)$$

$$Z(x) = \beta_1$$

前向后向概率：

1.位置 i 是标记 y_i

$$P(Y_i = y_i | x) = \frac{\alpha_i^T(y_i | x)\beta_i(y_i | x)}{Z(x)}$$

2.位置 i-1 和位置 i 是标记 y_{i-1} 和 y_i 的概率

$$P(Y_{i-1} = y_{i-1}, Y_i = y_i | x) = \frac{\alpha_{i-1}^T(y_{i-1} | x)M_i(y_{i-1}, y_i | x)\beta_i(y_i | x)}{Z(x)}$$

维特比算法求解最优路径：

转移概率 + 从前一状态到当前状态的转移得分

$$\delta_i(l) = \max_{1 \leq j \leq m} \{\delta_{i-1}(j) + w \cdot F_i(y_{i-1} = j, y_i = l, x)\}$$

对观测序列 $\mathbf{X} = \{x_1, x_2, x_3\}$ 进行词性（标签）标注，找到最优标注序列。

$Y = \{A, B, C\}$ (3 个标签，模拟常见词性标注场景，如 A=名词、B=动词、C=形容词)

$n = 3$ (观测词 x_1, x_2, x_3 ，对应标注 y_1, y_2, y_3)

$f_1(y_1=A, x_1)=1$ ，权重 $\lambda_1 = 1.2$; $f_2(y_1=B, x_1)=1$ ，权重 $\lambda_2 = 0.8$; $f_3(y_1=C, x_1)=1$ ，权重 $\lambda_3 = 1.0$ 。

$f_4(y_1=A, y_2=A)=1$ ，权重 $\lambda_4 = 0.6$; $f_5(y_1=A, y_2=B)=1$ ，权重 $\lambda_5 = 0.9$ 。

$f_6(y_1=A, y_2=C)=1$ ，权重 $\lambda_6 = 0.4$; $f_7(y_1=B, y_2=A)=1$ ，权重 $\lambda_7 = 0.5$ 。

$f_8(y_1=B, y_2=B)=1$ ，权重 $\lambda_8 = 0.7$; $f_9(y_1=B, y_2=C)=1$ ，权重 $\lambda_9 = 1.1$ 。

$f_{10}(y_1=C, y_2=A)=1$ ，权重 $\lambda_{10} = 0.3$; $f_{11}(y_1=C, y_2=B)=1$ ，权重 $\lambda_{11} = 0.8$ 。

$f_{12}(y_1=C, y_2=C)=1$ ，权重 $\lambda_{12} = 0.6$

	$Y_1 - Y_2$	$Y_2 \rightarrow Y_3$	
	$A \rightarrow A$	$\lambda = 0.6$	$C \rightarrow A$ $\lambda = 0.3$
	$A \rightarrow B$	$\lambda = 0.9$	$C \rightarrow B$ $\lambda = 0.8$
A	$y_1=A$ $\lambda = 1.2$	$A \rightarrow C$ $\lambda = 0.4$	$C \rightarrow C$ $\lambda = 0.6$
B	$y_1=B$ $\lambda = 0.8$	$B \rightarrow A$ $\lambda = 0.5$	
C	$y_1=C$ $\lambda = 1.0$	$B \rightarrow B$ $\lambda = 0.7$	
		$B \rightarrow C$ $\lambda = 1.1$	


1层

2层

$M_2(A) = \{ \underbrace{1.2 + 0.6}_{\text{转移+状态(前)}}, 0.8 + 0.9, 1.0 + 0.4 \} + 1.2 = 3.0$

$M_2(B) = \{ \underbrace{1.2 + 0.9}, 0.8 + 0.5, 1.0 + 0.8 \} + 0.8 = 2.9$

$M_2(C) = \{ 1.2 + 0.4, 0.8 + 1.1, 1.0 + 0.6 \} + 1.0 = 2.9$



3层

$M_3(A) = \{ \underbrace{3.0 + 0.6}, 2.9 + 0.5, 2.9 + 0.3 \} + 1.2 = 4.6$

$M_3(B) = \{ \underbrace{2.0 + 0.9}, 2.9 + 0.7, 2.9 + 0.8 \} + 0.8 = 4.1$

$M_3(C) = \{ 3.0 + 0.4, \underbrace{2.9 + 1.1}, 2.9 + 0.6 \} + 1.0 = 5.0$

语言模型

语言模型定义

刻画真实世界语言中词与词之间联系规律的模型

什么是 n 元文法

只考虑前 N-1 个词对于后续词出现概率的影响，从而创建成的语言模型，即为 N-gram 模型。

给定 n 元文法，计算某个句子出现的概率：

<BOS> John read a book <EOS> 基于2元文法的概率为：

$$p(\text{John read a book}) = p(\text{John}|\text{<BOS>}) \times p(\text{read}|\text{John}) \times p(a|\text{read}) \times p(\text{book}|a) \times p(\text{<EOS>}|\text{book})$$

<BOS>John read Moby Dick<EOS>
<BOS>Mary read a different book<EOS>
<BOS>She read a book by Cher<EOS>

$$p(\text{John read a book}) =$$

$$\begin{aligned} p(\text{John}|\text{<BOS>}) &= \frac{c(\text{<BOS> John})}{\sum_w c(\text{<BOS> } w)} = \frac{1}{3} & p(a|\text{read}) &= \frac{c(\text{read a})}{\sum_w c(\text{read } w)} = \frac{2}{3} \\ p(\text{read}|\text{John}) &= \frac{c(\text{John read})}{\sum_w c(\text{John } w)} = \frac{1}{1} & p(\text{book}|a) &= \frac{c(a \text{ book})}{\sum_w c(a \text{ } w)} = \frac{1}{2} \\ p(\text{<EOS>}|\text{book}) &= \frac{c(\text{book <EOS>})}{\sum_w c(\text{book } w)} = \frac{1}{2} \\ p(\text{John read a book}) &= \frac{1}{3} \times 1 \times \frac{2}{3} \times \frac{1}{2} \times \frac{1}{2} \approx 0.06 \end{aligned}$$

缺点：

N 的增加，参数量变大；语料的稀疏性

数据平滑：降低高概率提升低概率

加法平滑法“加一法”：分子+1；分母+不重复的词元的数量

对于 2-gram 有：

$$\begin{aligned} p(w_i | w_{i-1}) &= \frac{1 + c(w_{i-1} w_i)}{\sum_{w_i} [1 + c(w_{i-1} w_i)]} \\ &= \frac{1 + c(w_{i-1} w_i)}{|V| + \sum_{w_i} c(w_{i-1} w_i)} \end{aligned}$$

其中，V 为被考虑语料的词汇量，即全部可能的基元数。

加法平滑法改进：

加一个 0-1 之间的常数 δ

$$p_{\text{add}}(w_i | w_{i-n+1}^{i-1}) = \frac{c(w_{i-n+1}^i) + \delta}{\sum_{w_i} c(w_{i-n+1}^i) + \delta|V|}$$

减值平滑法：

Good-Turing 估计在样本中出现 r 次的事件的概率为：

$$r^* = (r + 1) \frac{n_{r+1}}{n_r}$$

$$p_r = \frac{r^*}{N}$$

原训练样本所有事件的概率之和：

$$\sum_{r>0} n_r \times p_r = 1 - \frac{n_1}{N} < 1$$

$\frac{n_1}{N}$ 的剩余概率量就可以均分给 $r = 0$ 的事件

Katz 后退法：三种情况+如何计算： k 为频数阈值

$$p_{\text{katz}}(w_i | w_{i-n+1}^{i-1}) = \begin{cases} P_{ML}(w_i | w_{i-n+1}^{i-1}), & \text{if } c(w_{i-n+1}^i) \geq k, \\ \alpha \cdot P_{GT}(w_i | w_{i-n+1}^{i-1}), & \text{if } 1 \leq c(w_{i-n+1}^i) < k, \\ \beta \cdot P_{\text{katz}}(w_i | w_{i-n+2}^{i-1}), & \text{if } c(w_{i-n+1}^i) = 0. \end{cases}$$

高频 使用MLE
低频 使用折扣
0次 使用回退

例子：

1. 计算 $r=1$ 、 $r=2$ 对应的调整后频数 r^* ；核心公式： $r^* = (r+1) \times N_{(r+1)} / N_r$ 。
 $r=1$ 时： $1^* = (1+1) \times N_2 / N_1 = 2 \times 4 / 16 = 0.5000$ 。
 $r=2$ 时： $2^* = (2+1) \times N_3 / N_2 = 3 \times 0 / 4 = 0.0000$ 。
2. 计算前缀“他”的归一化后推常数 $\alpha(w_i)$ 。
计算出现过的 Bigram 调整后频数总和：
16 个 $r=1$ 的 Bigram： $16 \times 0.5000 = 8.0000$ ；4 个 $r=2$ 的 Bigram： $4 \times 0.0000 = 0.0000$ 。
总调整频数和： $8.0000 + 0.0000 = 8.0000$ 。
计算出现过的 Bigram 总概率和 $\sum P_{\text{katz}}(\text{出现}) = \text{总调整频数和} / C(w_i) = 8.0000 / 80 = 0.1000$ 。
计算未出现的 Bigram 的 Unigram 概率和 $\sum P_{ML}(\text{未出现}) = 1 - \sum P_{ML}(\text{出现})$ 。
本题简化取 $\sum P_{ML}(\text{未出现}) = 0.9000$ （符合总概率守恒）。
计算 $\alpha(w_i) = (1 - 0.1000) / 0.9000 = 1.0000$ 。
3. 分别计算 $P_{\text{katz}}(\text{说}|\text{他})$ 、 $P_{\text{katz}}(\text{去}|\text{他})$ 、 $P_{\text{katz}}(\text{看}|\text{他})$ 。
 $P_{\text{katz}}(\text{说}|\text{他})$ ： $c=1$ （出现过），用调整后频数 $P = r^* / C(w_i) = 0.5000 / 80 = 0.00625$ 。
 $P_{\text{katz}}(\text{去}|\text{他})$ ： $c=2$ （出现过），用调整后频数 $P = r^* / C(w_i) = 1 / 80$ 。
 $P_{\text{katz}}(\text{看}|\text{他})$ ： $c=0$ （未出现），用后推公式 $P = \alpha(w_i) \times P_{ML}(\text{看}) = 1.0000 \times 0.02 = 0.0200$ 。

已知某语料库中，前缀词 $w="他"$ 的相关统计数据如下表（所有数据均为以“他”开头的 Bigram 统计）。全局 Unigram 最大似然概率： $P_{ML}(\text{说})=0.06$ ， $P_{ML}(\text{去})=0.04$ ， $P_{ML}(\text{看})=0.02$ ；Katz 平滑参数：折扣阈值 $k=5$ ，折扣常数 $d=1$ 。

原始频数 r	该频次的 Bigram 种类数 N_r
1	16
2	4
$r \geq 3$	0

补充条件：以“他”开头的 所有 Bigram 总出现次数 $C(w_i)=80$ ；目标 Bigram： $c(\text{他, 说})=1$ ， $c(\text{他, 去})=2$ ， $c(\text{他, 看})=0$ （未出现）。

折扣阈值： $c(\text{他, 说})=1$ ； $c(\text{他, 去})=2$ ； $c(\text{他, 看})=0$

1) 计算调整后阈值： r^*

$$r^* = (r + 1) \frac{n_{r+1}}{n_r}$$

2) 计算出现的总概率次数：

0.1 出现； $1 - 0.1 = 0.9$ 分配给未出现的情况

16 个 $r=1$ 的 Bigram： $16 \times 0.5000 = 8.0000$ ；4 个 $r=2$ 的 Bigram： $4 \times 0.0000 = 0.0000$ 。

总调整频数和： $8.0000 + 0.0000 = 8.0000$ 。

计算出现过的 Bigram 总概率和 $\sum P_{\text{katz}}(\text{出现}) = \text{总调整频数和} / C(w_i) = 8.0000 / 80 = 0.1000$ 。

α_w 默认为 1

3)

对于 $P_{\text{katz}}(\text{说}|\text{他})$ 使用折扣： $1 < 5$

$$1^* = (1 + 1) \frac{N_2}{N_1} = 2 \times \frac{4}{16} = 0.5$$

$$P_{\text{katz}}(\text{说} | \text{他}) = \alpha_w \cdot P_{GT}(\text{说} | \text{他}) = \alpha_w \cdot \frac{1^*}{C(\text{他})}$$

对于 $P_{\text{katz}}(\text{去} | \text{他})$ 使用折扣: $2 < 5$

$$2^* = (2 + 1) \frac{N_3}{N_2} = 3 \times \frac{0}{4} = 0$$

$$P_{\text{katz}}(\text{去} | \text{他}) = \alpha_w \cdot P_{GT}(\text{去} | \text{他}) = \alpha_w \cdot \frac{2^*}{C(\text{他})}$$

对于 $P_{\text{katz}}(\text{看} | \text{他})$ 使用回退: 0

因为 $c(\text{他}, \text{说})=1$; $c(\text{他}, \text{去})=2$, 所以减去 $P_{ML}(\text{说})$ 和 $P_{ML}(\text{去})$

$$\beta = \frac{1 - \sum_{c(\text{他}, w) > 0} P_{\text{discount}}(w | \text{他})}{1 - P_{ML}(\text{说}) - P_{ML}(\text{去})} = \frac{\text{高阶模型中留给未出现事件的概率质量}}{\text{低阶模型中未出现事件原本占的概率质量}} = 1$$

$$P_{\text{katz}}(\text{看} | \text{他}) = \beta \cdot P_{ML}(\text{看})$$

方法区别:

Good-Turing 法: 对非 0 事件按 <u>公式</u> 削减出现的次数, 节留下来的概率均分给 0 概率事件。
Katz 后退法: 对非 0 事件按 Good-Turing 法计算减值, 节留下来的概率按 <u>低阶</u> 分布分给 0 概率事件。
绝对减值法: 对非 0 事件无条件削减某一 <u>固定</u> 的出现次数值, 节留下来的概率均分给 0 概率事件。
线性减值法: 对非 0 事件根据出现次数按 <u>比例</u> 削减次数值, 节留下来的概率均分给 0 概率事件。

语料库

语料库定义：

存放语言材料的仓库

判断语料库类型：

China Tree Bank/ Tree Bank

Tree Bank 标记：大一→小 拆解再递归回来

短语层级标签			词性标签		
符号	含义	解析	符号	含义	解析
IP	句子	小句，整个句子的最高层级	NN	普通名词	如“苹果”“房间”“故事”
NP	名词短语	由名词、代词、数量词等构成	NR	专有名词	如“北京”“小明”“长城”
VP	动词短语	由动词、动词+宾语/补语等构成	NT	时间名词	如“今天”“明天”“去年”
PP	介词短语	介词+名词短语，如“在图书馆”	PN	代词	如“我”“他”“我们”“这”
ADJP	形容词短语	由形容词、副词+形容词构成	VV	动词	如“吃”“看”“打扫”“旅行”
ADVP	副词短语	由副词或副词性成分构成	VA	形容词	如“美丽”“好”“感人”“干净”
QP	数量短语	数词+量词，如“一碗”“三个”	AD	副词	如“很”“慢慢”“飞快”“按时”
CLP	量词短语	单独量词或量词相关搭配	P	介词	如“在”“把”“从”“给”
CP	“的”字结构/定语从句结构	含小句+“的”	M	量词	如“碗”“本”“个”
DNP	“的”字短语	名词短语+“的”	CD	数词	如“一”“三”“十”
			LC	方位词	如“里”“外”“上”“下”
			DEG	“的”	定语后的“的”
			DER	“地”	状语后的“地”
			DEC	“得”	补语前的“得”
			AS	体貌助词	“着”“了”“过”“去”
			PU	标点符号	“。”“，”“？”“。”
			SP	句末语气词	“吗”“呢”“啊”
			CS	连词	让步、条件连词，如“虽然”“只”
			CC	并列连词	如“但”“和”“而且”
			MD	情态动词	如“能”“会”“应该”“才能”
			DT	指示代词	如“这”“那”

1) 今天天气很好。

IP
 NP (NT 今天)
 NP (NN 天气)
 ADJP
 ADVP (很)
 VA (好)
 (PU。)

PU ⇒ 标点。

2) 美丽的花朵开放了。

IP
 NP
 ADJP
 (VA 美丽)
 (DEG 的)
 NP
 (NN (花朵))
 VP
 (VV 开放)
 (AS 了)
 (PU。)

论元标记-PropBank:

(1) 核心论元 (Arg0-Arg6)

Arg0: 施事者 (Volitional Actor)，通常是有意志的动作发起者，对应典型的施事角色 (Agent)。

Arg1: 受事者 (Patient/Theme)，动作直接影响的对象，是谓词最核心的受影响论元。

Arg2: 工具 (Instrument)、受益者 (Benefactive) 或属性 (Attribute)，辅助动作完成的对象或动作的受益方。

Arg3: 起点 (Starting Point)、受益者或属性，动作的起始位置或额外的受益对象。

Arg4: 终点 (Ending Point)，动作的最终目的地或完成后的状态终点。

Arg5-Arg6: 特殊论元，仅用于少数特定谓词 (如复杂动作的多个参与者)，使用频率较低。

(2) 附加论元 (ArgM-XX) 附加论元是谓词的修饰成分，语义含义固定，不随谓词变化，共13种通用标签

ArgM-MNR: 方式 (Manner)，描述动作的执行方式 (如“认真地”“私下地”)。

ArgM-LOC: 地点 (Locative)，动作发生的地点 (如“在图书馆”“在公园里”)。

ArgM-TMP: 时间 (Temporal)，动作发生的时间 (如“昨天”“在周四”)。

ArgM-CAU: 原因 (Cause)，动作发生的原因 (如“因为下雨”“由于生病”)。

ArgM-PURP: 目的 (Purpose)，动作的目的 (如“为了学习”“为了赚钱”)。

ArgM-NEG: 否定 (Negation)，表示动作的否定状态 (如“不”“没有”“不会”)。

ArgM-MOD: 情态 (Modality)，表示动作的情态 (如“可能”“会”“应该”)。

The wind blew the leaves away
Arg0 Rol Arg1 Arg2

(3) **谓词标记 (Rel)** 谓词是句子的核心，通常为动词 (如“吃”“看”“打扫”)，部分名词 (如“offer”) 和形容词也可作为谓词，标注时需在谓词后标注义项ID (如run.02、accept.01)，明确谓词的具体语义。

Word Net 的类型、模块：

是一种以同义词集 Synset 为核心的词汇语义网络。

按词性分为：名词库、动词库、形容词库、副词库

常见关系：同义关系、反义关系、上位关系、下位关系、部分-整体关系

How Net 代表的类型、模块：

是一种以义原为核心的概念语义知识库

主要包括：概念词典、义原系统、语义关系描述、属性与角色关系