

绪论

什么是自然语言处理？自然语言处理与人工智能的关系如何理解？

一门旨在实现让计算机模拟人类对自然语言进行智能化处理的技术；

自然语言：随着社会发展进程自然产生并发展演化的用于人类进行日常交流与思考的符号系统；

自然语言处理的核心任务：转换、理解、生成

自然语言处理过程的主要困难是什么？请举例说明

歧义（同一形式下存在多种含义）、病构（未知语言现象）

自然语言处理的研究内容可以划分为哪些层次，各层次有哪些具体的研究内容？

应用层研究：机器翻译、信息检索、自动文摘、问答系统、文档分类、信息抽取、对话系统；

应用基础研究：词法分析、句法分析、语义分析、篇章分析；

基础研究：语言模型、语料库建设、语言知识库建设、字符集编码体系

语义分析：

建立语言符号与客观世界的真实知识内涵之间的计算模型

词义消歧、语义角色标注、共指消解

自然语言处理的基本方法分为哪几类？请简单说明其各自的主要特点？

经验主义：基于大规模真实语料；

理性主义：基于规则的分析方法

信息检索

信息检索：

指从大规模非结构化数据（通常是文本）集合中找出满足用户信息需求的资料的过程

预处理：

中文分词、词性标注、虚词过滤

文本标引：

特征选择（基于频率；信息增益；卡方检验；互信息）、权重计算（TF-IDF）、向量编码（VSM）

VSM 信息检索技术框架的关键点：

索引项 t 选择：怎样确定文档中哪些词项是重要的词项

索引项权重 W_{t_k} 计算：怎样确定一个词项在某个文档中的重要程度

相似度 S 评价：怎样确定一个文档和一个查询式之间的相似度

LSI 优势：

可以用奇异值来过滤次要的“语义维度”，起到滤除噪声的效果；

分解出语义层作为中介后，可将同义词用语义层联系起来；

分解出语义层的过程中，多义词的重要性被自动下降到几乎不起作用的程度（多义词的权重被分配了）

LSI 中 C, U, V^T, Σ 四个矩阵的含义：

$$C = U \Sigma V^T$$

C ：词项-文档矩阵

词项矩阵- U ：词项-语义矩阵

文档矩阵 V^T : 语义-文档矩阵

奇异值矩阵 Σ : 代表各语义维度的权重

问答系统的概念+当前实现类型:

允许用户以自然语言方式询问, 系统能从大量的异构数据中查找并总结出用户问题答案的新型信息检索系统

基于大规模真实文本的问答系统

基于 Web 的问答系统

基于知识库的问答系统

基于语言模型的理解式问答系统

信息检索模型框架:

基于布尔模型的技术框架 (Lucene)、基于 VSM 模型的技术框架、

基于语言模型的技术框架、基于概率模型的技术框架

评价指标:

Precision@N、R- Precision、Precision vs Recall curve

TREC 竞赛 QA 任务评测指标:

MRR、CWS、Accuracy

词法分析

词法分析的主要任务:

汉语自动分词、英语形态还原、命名实体识别、词性标注

研究方法:

经验主义: 基于大规模真实语料; 理性主义: 基于规则的分析方法

汉语分词的主要方法:

最大匹配法 (基于词典的机械切分法-正向、逆向、双向);

最短路径法 (基于词典的启发式切分法);

最大概率法 (基于 N 元语法模型的分词法);

字分类法 (基于字构成词的统计特征分词法)

字分类法分词原理: (序列标注问题) CRF, HMM

将分词过程看作是字的分类问题。该方法认为, 每个字在构造一个特定的词语时都占据着一个确定的构词位置, 即词位。

假定每个字只有 4 个词位: 词首 B 、词中 M 、词尾 E 和单独成词 S

词性 (POS):

指词汇的基本语法属性, 通常用类别的方式来定义区分词汇的基本语法属性

词性标注方法:

基于规则: 基于人工设计的规则、基于自动提取的规则

基于统计: 基于 HMM 模型的词性标注方法

简述命名实体识别的概念:

识别文本中对实体的命名性指称, 具体来讲就是识别文本中的人名、地名、机构名、时间名等专有名词

主要方法: 基于规则、基于统计 (CRF)、基于深度学习

序列标注模型:

HMM、CRF、SVM、ANN

特殊性: (本质上是一个机器学习的分类问题)

从开头到末尾逐个对每一单元进行分类
仅基于待分类单元的上下游信息构建分类器

北大版词性标注集的基本词性代码：

名词(n)、时间词(t)、处所词(s)、方位词(f)、数词(m)、量词(q)、区别词(b)、代词(r)、动词(v)、形容词(a)、状态词(z)、副词(d)、介词(p)、连词(c)、助词(u)、语气词(y)、叹词(e)、拟声词(o)、成语(i)、习用语(l)、简称(j)、前接成分(h)、后接成分(k)、语素(g)、非语素字(x)、标点符号(w)。

如何利用 HMM 建立词性标注器：

使用 HMM 模型确定 A, B, π 矩阵，在已知单词序列 O 的情况下，使用维特比算法计算最优状态序列

使用正向、反向最大匹配法对句子进行分词：

词典：自动化研究所、自动化、研究所、自动、研究、取得、成就、非常、常人、能干、干到

句子：自动化研究所取得的成就非常人能干到

正向：自动化研究所 / 取得 / 的 / 成就 / 非常 / 人 / 能干 / 到

反向：自动化研究所 / 取得 / 的 / 成就 / 非 / 常人 / 能 / 干到

句法结构

句法分析：

自然语言处理过程中限于句子层面上的形式化分析，核心目标是确定句子的句法结构或句子词汇之间的依存关系

句法分析分类：

句法结构分析：完全句法分析+浅层句法分析

依存关系分析

句法结构分析概念：

指对输入的单词序列（句子）判断其构成是否合乎给定的语法规则，以及确定出符合语法规则的句法结构

语法规则库的构建：

基于人工规则的方法、基于统计（机器学习）的方法

句法结构分析器的性能评价：

精度、召回率、F-measure

浅层句法分析概念：

仅关注于局部区域范围内的语法属性，不关注远距离的语法关联特征

仅辨识：

非递归的名词短语（Base NP：结构上独立）/动词词组（VG）/介词短语（PP）/副词短语（DP）

Base NP 识别方法：看作序列标注任务--->CRF, SVM

依存句法分析概念：

研究句子中“关联”特性的理论部分，突出动词的中心地位

依存句法结构描述：

有向图方法、依存树方法、依存投射树方法

依存关系分析算法：

生成式的分析方法（基于转移的方法）、判别式的分析方法（基于图、序列标注的方法）、决策式的（确定性的）分析方法、基于约束满足的分析方法

请简述术语含义：

S、VP、NP、PP； SBV、VOB、ATT、DE

S：句子；VP：动词短语；NP：名词短语；

PP：介词短语；SBV：主谓关系；VOB：动宾关系；

ATT：定中关系；DE：的字结构。

PCFG 模型特点，采用 PCFG 模型进行句法分析的优势

特点：引入了概率参数 p ，可以计算句法生成树的生成概率

优势：

可以寻找最优句法结构

训练得到的语法规则更加贴近实际语义

降低人工编制工作量和主观性

采用 CYK 算法对句子进行句法结构分析：

文法规则只有这两种形式： $A \rightarrow w$ 或 $A \rightarrow BC$

乔基姆范式化： $A \rightarrow BCD$ 则 $X \rightarrow CD$

注意：多种结构树可能

4. 请采用CYK算法对以下句子进行句法结构分析？（注意乔基姆范式化、注意多种结构树）

CFG文法： $S \rightarrow VC NP \mid VP Aux NP$;
 $VC \rightarrow v a \mid VC utl$;
 $NP \rightarrow n \mid NP Aux NP \mid NP NP$;
 $VP \rightarrow VC NP$

$v \rightarrow$ 咬;
 $a \rightarrow$ 死;
 $n \rightarrow$ 猫人(狗);
 $utl \rightarrow$ 了;
 $aux \rightarrow$ 的;

句子: 咬死了猫人危险

4. 请采用CYK算法对以下句子进行句法结构分析？（注意乔基姆范式化、注意多种结构树）

CFG文法： $S \rightarrow VC NP \mid VP Aux NP$;
 $VC \rightarrow v a \mid VC utl$;
 $NP \rightarrow n \mid NP Aux NP \mid NP NP$;
 $VP \rightarrow VC NP$

$v \rightarrow$ 咬;
 $a \rightarrow$ 死;
 $n \rightarrow$ 猫人(狗);
 $utl \rightarrow$ 了;
 $aux \rightarrow$ 的;

句子: 咬死了猫人危险

	V	VC	VC			S
咬	a					
	a	utl				
		3	n.NP			
			猫人	aux	X	
				的	n.NP	
						狗

	V	VC	VC	VP		S
咬	a					
	a	utl				
		3	n.NP			
			猫人	aux	X	
				的	n.NP	
						狗

语义分析

简述词义消歧的概念？目前主要的词义消歧方法分为那几类？

确定一个多义词在给定上下文语境中的具体含义。

基于规则的方法；基于有监督学习的方法（互信息、贝叶斯分类器、最大熵）；

基于词典的方法

上下文信息的特点：

邻近的上下文信息对于确定词性非常有效

相隔很远的实词对于确定词义往往更有效

基于词典的词义消歧有哪几种类型，分别简述其原理？

基于词典中语义定义：词典中词条本身定义作为判断其语义的条件

基于义类辞典的消歧方法：通过上下文的语义范畴判断多义词的使用义项
基于双语词典的消歧方法：把多义词 x 的不同义项翻译成另一种语言，统计不同词义的翻译与相关词 y 的翻译同时出现的次数

简述语义角色标注的概念？自然语言处理中常用有哪些语义角色？

以句子的谓词为中心，研究句子中各成分与谓词之间的关系，并用语义角色来描述和区分这些关系

英文领域：

与具体谓词直接相关的（ARG）；起修饰性作用的辅助性角色（ARGM）

中文领域：

核心语义角色（ARG）；起修饰性作用的辅助性角色（ARGM）

例：ARG0：施事者；ARG1：受事者；ARG2：范围或程度；ARG3：动作起点；.....

语义角色	角色描述	语义角色	角色描述
ARG0	施事者	ARG1	受事者
ARG2	范围或程度	ARG3	动作起点
ARG4	动作结束点	ARGM-ADV	状语
ARGM-BNF	受益者	ARGM-CND	条件
ARGM-DIR	方向	ARGM-LOC	地点
ARGM-MNR	方式	ARM-PRP	目的
ARGM-TMP	时间	ARGM-TPC	主题
ARGM-PRD	次谓词		

语义角色标注方法：

基于短语结构树、基于依存关系树---最大熵、SVM、感知机

基于浅层句法语块（作为一个序列标注问题）

简述基于短语结构树的语义角色标注方法与基于依存关系树的语义角色标注方法之间的核心差异？

短语结构树：标注对象为短语，特征信息主要从句法结构树中抽取

依存关系树：标注对象为词语，特征信息主要从句法依存树中抽取

预训练词向量

简述 NLP 从基于统计机器学习过渡到当前基于预训练模型的发展过程，以及过程中各阶段的核心特征？

小规模专家系统：使用离散的语言符号来表示词

语料库统计模型阶段：使用离散、高维稀疏的向量表示词(one-hot vector)

深度学习模型：需要先把词语表示成低维、稠密、连续向量

大规模预训练模型阶段：预训练+精调=自然语言处理新范式

简述词表示模型的发展过程，以及不同过程的代表性模型？

离散表示：为词汇表中的每个词分配一个唯一的索引

One-hot 给每个词分配唯一索引，用一个高维稀疏向量表示词。

One-hot 问题：维度灾难、语义鸿沟、泛化能力有限

分布表示：词的含义可由其上下文词的分布进行表示

LSA 通过构建词共现矩阵，并使用奇异值分解来降低稀疏性、反映高阶共现关系。

HAL 通过固定长度滑动窗口统计词与词之间的共现关系，并按照距离进行加权，最终得到高维的加权词语共现矩阵。（核心基石-分布假说）

分布式表示：

预训练静态词向量（NNLM, RNNLM, Word2vec, GloVe）

使用低维、稠密、连续的向量表示词，通过自监督学习方法学习词向量，效果优于直接统计方法。

预训练动态词向量（ELMo, BERT, GPT）

词向量不是固定表格，根据上下文由神经网络动态生成，可以处理一词多义问题。

内部任务评价方法：

词义相似度计算、词类比关系计算

外部任务评价方法：

知识图谱补全、推荐系统

简述静态词向量与动态词向量之间的核心差异，以及各自的优劣势？

核心差异：

静态词向量是一词一向量：训练好的词向量矩阵本质上是一张固定表格，每个词拥有一个固定向量。无论这个词出现在什么语境中，向量都相同。

动态词向量是一词多向量：保存的是训练好的神经网络模型，模型会根据上下文实时计算词的表示向量。

静态词向量的优势：向量结构简单，训练和推理速度快，计算开销小

静态词向量的劣势：无法处理一词多义，同一个词只有一个固定向量，不同语境下的词义差异无法体现。

动态词向量的优势：能够根据上下文生成不同表示，可以精准捕捉词语在具体句子中的语义变化，解决一词多义问题。

动态词向量的劣势：动态词向量通常基于更深层的神经网络，计算开销和推理成本更高。

在 Word2vec 模型中为什么需要采用负采样技术？

如果直接使用 Softmax 对目标词进行预测，需要在整个词表上计算概率并进行归一化。当词表很大、计算资源有限时，这种 Softmax 概率计算效率很低。

使用 1 表示共现，0 表示不共现

模型一览

基于神经网络语言模型：

前馈神经网络 FF-NNLM：前（n-1）个词预测当前词

循环神经网络 RNNLM：完整的历史预测当前词

基于局部上下文预测模型：

CBOW：根据周围词预测中间词

Skip-Gram：根据中间词独立地预测周围词

基于全局词频统计模型的词向量：

GloVe 模型：利用全局的“词-上下文”共现信息

ELMo：双向 LSTM+加权平均

动态、鲁棒、层次